Roubo ou furto? Classificação de ocorrências em São Paulo com MLP

Global Solution — Aprendizado Profundo com Redes Neurais Convolucionais

Integrantes: Gabriel Lima da Silva (RM 568436) · Nicolas Araujo de Oliveira (RM 566780)

Objetivo: construir, comparar e implantar uma MLP que indica se uma ocorrência já registrada é mais compatível com ROUBO ou FURTO.

O modelo classifica o TIPO de uma ocorrência. Ele não prevê onde ou quando um crime vai acontecer.

Problema, fonte de dados e recorte

Fonte e recorte

SSP-SP · Portal de Estatísticas → Bases de Dados

https://www.ssp.sp.gov.br/estatistica/consultas

Arquivo(s): CelularesSubtraidos_2026.csv

Recorte: CIDADE (cidade dos fatos) = S.PAULO — não o município do registro

Registros

Brutos: 256.076 → capital: 150.990

Finais (amostra): 20.000 · roubo = 34.8%

Duplicidades por BO removidas: 14.291

Outras naturezas descartadas: 24.415 · BOs sem hora exata: 41.1%

Atributos de entrada e justificativa

bairro e tipo de local (contexto do fato) · dia da semana e período (rotina) · hora exata informada? (0/1).

Excluídos: rubrica/natureza (data leakage), nº do BO, dados pessoais, lat/long exatas.

Rótulo: rubrica contém ROUBO → 1; FURTO → 0; ambíguos descartados.

Preparação dos dados

Tratamento

Hora ausente (~41%) → período vem de DESCR_PERIODO + flag hora_informada

Texto normalizado (sem acentos)

Demais ausentes → descartados

Codificação

One-hot: bairro, tipo_local, dia_semana, período

Categorias com <30 casos no treino → 'infrequente'

Entradas da rede: 129 colunas

Escalonamento

Entradas são one-hot/binárias (0/1)

Sem variável contínua → padronização dispensada

Separação (estratificada pela classe)

Treino 14.000 (70%) · Validação 3.000 (15%) · Teste 3.000 (15%)

Pré-processador ajustado (fit) só no treino → sem vazamento de informação do teste.

Teste usado uma única vez, no modelo já escolhido pela validação.

Arquitetura da MLP selecionada

Entrada (129) → Dense 16 (relu) → Dense 1 (sigmoide)

Como a rede funciona

Cada neurônio: a = f(W·x + b).

Camadas ocultas combinam atributos de forma não linear (ex.: 'via pública' E 'noite').

Saída sigmoide = P(roubo) entre 0 e 1; limiar 0,5.

Modelo escolhido: A_simples (16) — 2.080 pesos.

Por que essas escolhas

ReLU: simples e evita saturação do gradiente.

Sigmoide na saída: classificação binária com probabilidade.

Parcimônia: entre modelos com F1 equivalente (±0,5 p.p.), escolhe-se o menor.

Configuração do treinamento

Hiperparâmetros

Perda: entropia cruzada binária (log-loss)

Otimizador: Adam

Taxa de aprendizado: 0.001

Batch size: 128

Épocas: até 80 com early stopping (paciência 8)

Regularização L2 (alpha): 0.0001

Early stopping

Monitora a perda de VALIDAÇÃO a cada época.

Para quando não melhora por 8 épocas e restaura os melhores pesos.

Selecionado: melhor época 20 de 28 executadas.

Arquiteturas testadas e justificativas

Config.	Camadas ocultas	Ativação	L2	Por que testar
A	16	relu	0.0001	Linha de base pequena: há subajuste?
B	64-32	relu	0.0001	Mais capacidade (2 camadas)
C	128-64-32	relu	1e-05	Rede profunda, pouca regularização
D	128-64-32	relu	0.1	Mesma rede de C com L2 forte: efeito da regularização
E	64-32	tanh	0.0001	Mesma rede de B com tanh: efeito da ativação

Uma mudança principal por comparação (profundidade/largura, regularização, ativação), com dados, divisão e semente fixos.

Comparação dos modelos (validação) e escolha

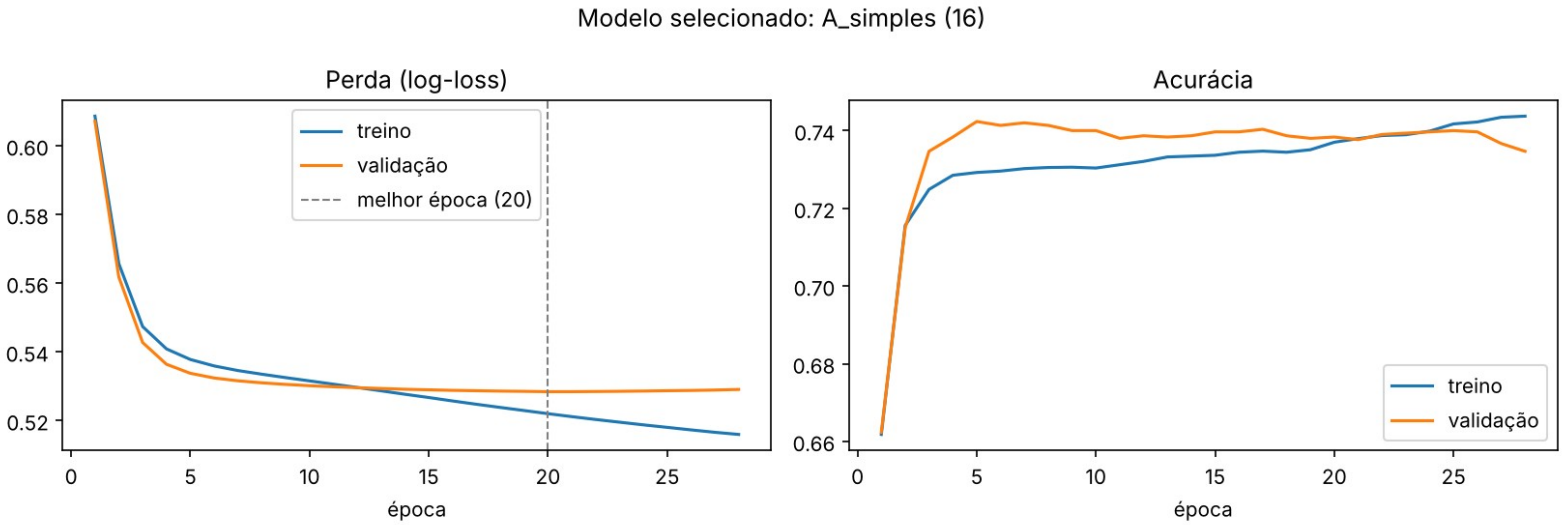
Modelo	Acurácia	Precision	Recall	F1	Pesos
A_simples (16)	**73.8%**	**64.3%**	**55.7%**	**59.7%**	**2.080**
B_media (64-32)	73.4%	67.9%	44.4%	53.7%	10.336
C_profunda (128-64-32)	73.1%	68.0%	42.8%	52.6%	26.784
D_profunda_L2 (128-64-32)	73.5%	73.0%	37.7%	49.7%	26.784
E_tanh (64-32)	73.4%	68.5%	43.7%	53.3%	10.336

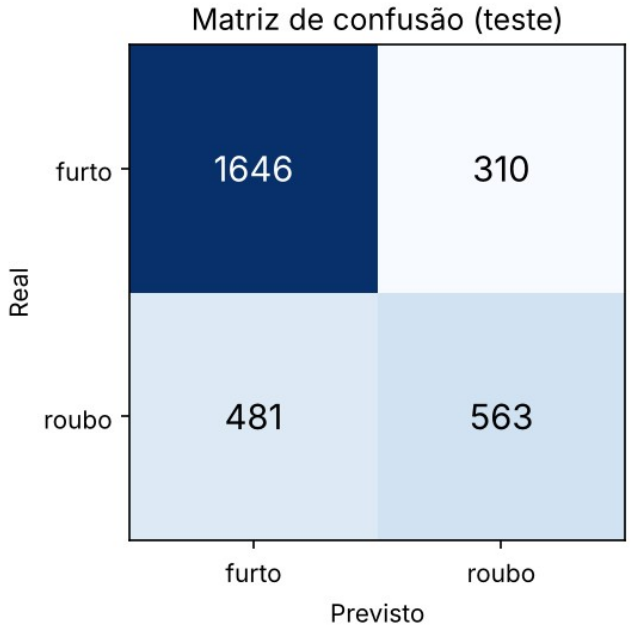
Escolhido: A_simples (16) (maior F1 na validação; empate técnico → menos pesos).

Teste final: acurácia 73.6% · precision 64.5% · recall 53.9% · F1 58.7% (classe positiva = roubo).

Baseline 'sempre a classe majoritária' (furto): acurácia 65.2% — a MLP supera em 8.4 p.p.

Curvas, matriz de confusão e diagnóstico



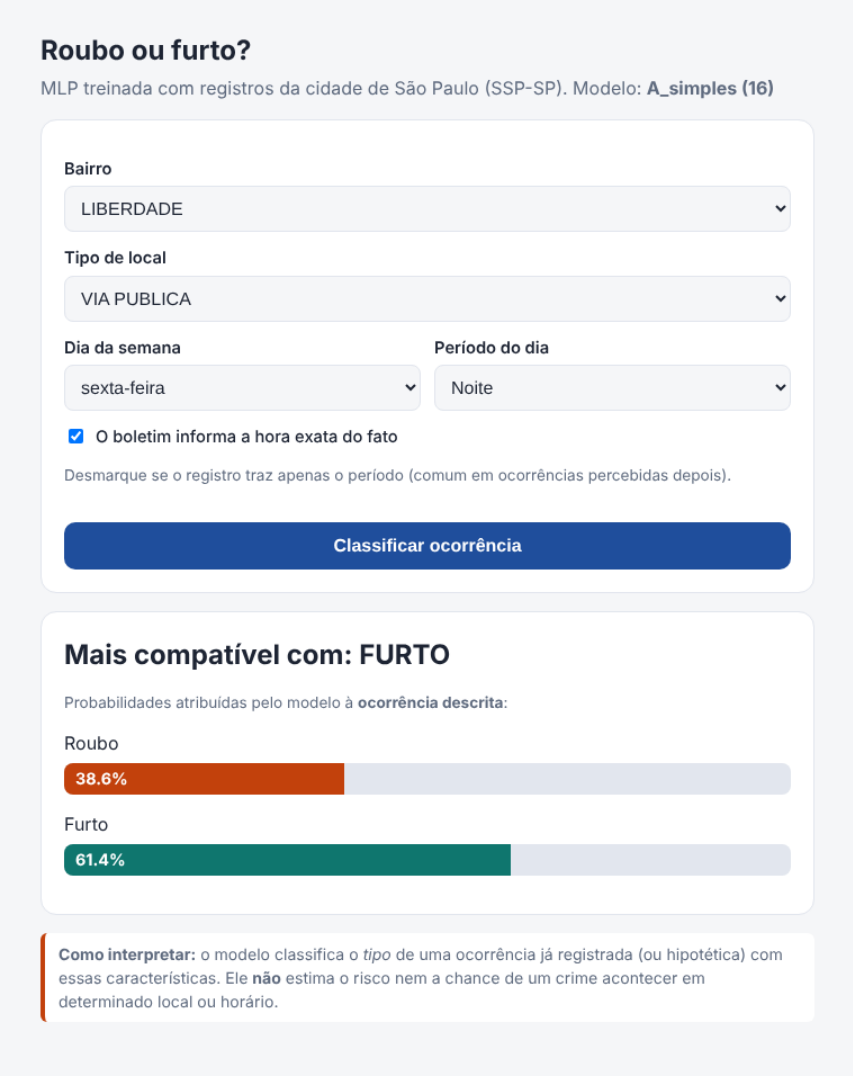


Acurácia treino–validação: -0.1 p.p.; melhor época = 20 de 28.

Curvas de treino e validação próximas → sem overfitting relevante; sem sinais de underfitting grave (supera o baseline).

Redes maiores (C, D) não superaram a pequena: o limite está na informação dos atributos, não na capacidade da rede.

Aplicação web



Funcionalidades e integração

Formulário: bairro, tipo de local, dia da semana, período e 'hora exata informada' — exatamente os atributos do treino.

Flask carrega o pipeline salvo (one-hot + MLP) e chama predict_proba.

Resultado: classe estimada + probabilidades de roubo e furto.

Aviso fixo: não é risco de crime. Valores raros → categoria 'infrequente'.

Endpoints: GET / · POST /api/predict · GET /health.

Link: https://claude.ai/artifact/8WTRgG4cbjwM8Awmh2txn4

Conclusões, limitações e uso de IA generativa

- Melhor modelo: A_simples (16) — F1 de teste 58.7%, acurácia 73.6%.
- Baseline (sempre furto) = 65.2%; a MLP supera, mas o recall de roubo é modesto (53.9%).
- Redes maiores não ajudaram: os atributos disponíveis limitam o desempenho.
- Ablação: sem 'hora exata informada' o F1 cai de 59.7% para 52.0% — o atributo reflete como o BO foi registrado.
- Limitações: subnotificação, rubrica depende do registro, vieses geográficos, bairros raros agrupados, só BOs de 2026.
- Uso ético: não serve para policiamento preditivo nem para julgar pessoas ou locais.
- Próximos passos: mais anos, validação temporal, calibração de probabilidades, ajuste do limiar.
- IA generativa (Claude): apoiou estrutura do código, depuração e documentação; a equipe revisou, executou e sabe explicar cada etapa.